

Tarea 2

Taller de Obtención y Preparación de Datos

Instrucciones Generales

Resuelva en grupos de máximo 2 personas la siguiente guía de ejercicios. Recuerde inscribir su grupo en la sección de *Canvas* → *Personas* → *Grupos Tarea 2*. Suba su solución como un archivo que contenga toda la información con el formato t02_apellido1_apellido2 a *Canvas* → *Sección Tareas* → *Tarea 2*. En el caso de utilizar Jupyter Notebooks u otra herramienta similar, puede subir un notebook con todas las actividades claramente separadas en un archivo *.ipynb. En el caso de generar scripts de Python, entregue todas las actividades por separado en archivos *.py (las cuales deben venir en un archivo comprimido). Fecha de entrega: lunes 07 de octubre 2024 hasta las 23:59:59. No se aceptarán tareas fuera de plazo.

Ejercicio 1 (25 pts.)

Defina una función que, reciba un texto y lo convierta en una serie de pandas, cuyos valores sean las palabras del texto (sin diferenciar entre mayúsculas y minúsculas, ni considerar puntuación o caracteres especiales), y cuyos índices sean su respectiva frecuencia de aparición en dicho texto. Finalmente, su función debe retornar lo siguiente:

- La/s palabra/s con el mayor número de apariciones.
- La/s palabras con el menor número de apariciones.
- El número total de palabras únicas.
- El número total de palabras repetidas.
- La palabra cuya frecuencia de aparición es la mediana de los datos.

Ejercicio 2 (25 pts.)

Defina una función que reciba tres argumentos:

1. Una serie con datos de ventas diarias de una empresa (ordenadas por fecha de manera creciente),
2. un día específico, y
3. un rango de días.

Suponga que el formato de las fechas en la serie será DD-MM-AAAA, irán en los índices, y los respectivos montos de ventas serán los valores.

Su función deberá verificar si las fechas ingresadas como argumentos están en los datos o no. En caso de no estar, deberá imprimir un mensaje indicando que las fechas no corresponden a los datos, y en caso de estar; el día y/o el rango de días, deberá retornar lo siguiente:

1. El monto vendido para el día específico ingresado a la función, e imprimir un mensaje que indique si dicho día se vendió más, lo mismo, o menos que el promedio de los días anteriores, y/o
2. los valores máximo, mínimo y el promedio de ventas dentro del rango de días ingresados (incluyéndolos).

Ejercicio 3 (25 ptos.)

Escriba un programa que le solicite a n usuarios (el número n será un número aleatorio entre 15 y 25) ingresar sus respectivos: nombre, edad, genero, estatura (en cm.) y peso (en kg.); luego, guarde dicha información en un diccionario, en el orden que estime conveniente, y finalmente transforme dicho diccionario en un dataframe con 5 columnas: "nombres", "edad", "genero", "estatura", y "peso".

Sobre el dataframe ya construido, agregue una columna con el índice de masa corporal (IMC) de cada usuario.

Considere que el IMC se calcula de la siguiente forma:

$$IMC = peso (kg) / altura (m^2)$$

Luego, agregue otra columna con la siguiente clasificación según el IMC (para adultos) :

- **Bajo peso:** $IMC < 18.5$
- **Peso normal:** IMC entre 18.5 y 24.9
- **Sobrepeso:** IMC entre 25 y 29.9
- **Obesidad:** $IMC \geq 30$

Haga un análisis estadístico de los datos, calculando el promedio, valor mínimo y máximo, la moda, y la desviación estándar de: la estatura, peso e IMC de los usuarios.

Subdivida el dataframe original en uno para cada clasificación de IMC (los clasificados como bajo peso, peso normal, sobrepeso y obesidad), y vuelva a calcular las estadísticas antes mencionadas.

Luego de sus análisis cuantitativos, podría decir que existe alguna población más saludable, o en riesgo que otra? Si es así, qué cree que puede explicar dicha diferencia?

Ejercicio 4 (25 ptos.)

A continuación se entrega un código que permite simular datos de temperaturas anuales para realizar un análisis sobre tendencias de cambio climático.

```
'''  
import numpy as np  
  
# Generar los años  
years = np.arange(1900, 2021)  
# Generar temperaturas con tendencia creciente  
temperatures = 14 + 0.02 * (years - 1900) + np.random.normal(0, 0.5, len(years))  
'''
```

Usando los datos generados sobre las temperaturas medias globales simuladas entre los años 1900 y 2020, realiza el siguiente análisis estadístico:

Cálculos estadísticos:

- La temperatura media global.
- La temperatura mínima y la temperatura máxima.
- La desviación estándar y la varianza de las temperaturas.
- El año en el que se registró la temperatura más fría y el año con la temperatura más cálida.

Cambio anual de temperatura: Agrega una nueva columna al DataFrame que contenga el cambio de temperatura anual respecto al año anterior. Esta columna debe mostrar cómo ha variado la temperatura de un año a otro.

A partir del DataFrame con los datos de temperaturas simuladas, realiza las siguientes tareas de filtrado y agrupación:

Análisis de las últimas décadas:

- Filtra los datos para trabajar únicamente con los años entre 1950 y 2020.
- Calcula las temperaturas medias por cada década (1950-1960, 1960-1970, etc.) y muestra los resultados ordenados de la década más cálida a la más fría.

Años recientes por encima de la media:

- Calcula la temperatura media global de todo el período (1900-2020).
- Filtra los años comprendidos entre el 2000 y el 2020, y selecciona aquellos años en los que la temperatura estuvo por encima de la media global calculada en el paso anterior.

Con los datos filtrados y las temperaturas medias calculadas en las partes anteriores, realiza el

siguiente análisis para identificar patrones:

Identificación de las décadas más cálidas:

- Basándote en los cálculos realizados en la parte anterior, determina cuál fue la década más cálida y cuál fue la más fría entre 1950 y 2020.
- Compara las diferencias de temperatura entre las décadas y analiza si existe una aceleración en el aumento de las temperaturas.

Detección de tendencias recientes:

- Analiza los años recientes (2000-2020) y concluye si hay un aumento sostenido en la temperatura durante estos años en comparación con la media histórica.

Con base en el análisis estadístico, el filtrado de datos y los patrones identificados en las partes anteriores, responde las siguientes preguntas de análisis:

- ¿Qué tendencias generales observas en las temperaturas simuladas desde 1900 hasta 2020?
- ¿En qué década observas el cambio más acelerado en las temperaturas globales?
- ¿Cómo se comportaron las temperaturas en los últimos 20 años en comparación con el resto del período?
- A partir de los datos simulados, ¿qué conclusiones podrías sacar sobre el calentamiento global y su posible impacto en el futuro?